

Análisis Exhaustivo de Modelos Fundacionales y Matemáticos en el Trading Cuantitativo: Arquitecturas, Implementación y Marcos de Evaluación

Introducción al Nuevo Paradigma de Modelos en el Trading Cuantitativo

La industria del trading cuantitativo y algorítmico se encuentra inmersa en una transición estructural sin precedentes, abandonando los paradigmas de pronóstico econométrico clásico y los algoritmos de aprendizaje automático estandarizados para adoptar Modelos Fundacionales de Series Temporales (TSFMs, por sus siglas en inglés). A diferencia de los Modelos de Lenguaje Grande (LLMs) que procesan tokens textuales discretos con una semántica bien definida, los datos de series temporales financieras se caracterizan por valores numéricos continuos, proporciones de ruido a señal extremadamente altas, no estacionariedad intrínseca, heterocedasticidad y dependencias temporales complejas a múltiples escalas. Los recientes avances en arquitecturas de redes neuronales, específicamente la adaptación de los mecanismos de atención basados en transformadores y las transformadas convolucionales altamente optimizadas, han introducido modelos capaces de realizar pronósticos de disparo cero (zero-shot), ajustes finos con pocos datos (few-shot fine-tuning) y extracción de características robustas a través de múltiples modalidades financieras.

El propósito de este informe es proporcionar un análisis exhaustivo de la implementación, el entrenamiento y la mecánica arquitectónica de los modelos matemáticos y de inteligencia artificial en el dominio del trading bursátil. Se pone especial énfasis en la deconstrucción y el análisis de TimesFM de Google ¹, TSPulse de IBM ³ y el algoritmo de transformación determinista MiniRocket. ⁵ Además, en respuesta directa a los requerimientos del análisis de una implementación cuantitativa completa, este documento evalúa una canalización de trading tripartita que comprende archivos de precalculo de características, instrucciones de entrenamiento de modelos y un motor de backtesting (con ejecuciones específicas de TSPulse en la línea 427 y MiniRocket en la 480). Al contrastar esta implementación con casos de éxito institucionales probados y deconstruir la mecánica de la fuga de datos, los protocolos de validación y la alineación de ejecución, este informe sirve como una guía definitiva para refinar arquitecturas de trading e integrar modelos de IA de última generación.

Análisis Arquitectónico Profundo de los Modelos de Vanguardia

El diseño arquitectónico de un modelo predictivo dicta directamente su idoneidad para la ejecución algorítmica de alta frecuencia frente al rebalanceo de carteras de baja frecuencia.

Para comprender cómo estos modelos asimilan el comportamiento estocástico de los mercados financieros, es imperativo diseccionar sus mecanismos internos.

TimesFM: Atención Causal de Solo Decodificador para Pronósticos

Desarrollado por Google Research, TimesFM (Time Series Foundation Model) representa un hito fundamental al tratar el pronóstico de series temporales continuas estrictamente a través de una lente de transformador de solo decodificador.² Preentrenado en un corpus masivo que supera los 100 mil millones de puntos de tiempo del mundo real, TimesFM está diseñado principalmente para ejecutar tareas de pronóstico de disparo cero, aunque su verdadera utilidad en la inversión cuantitativa se desbloquea a través de un ajuste fino específico para la tarea de predicción de precios.¹

La mecánica arquitectónica de TimesFM difiere sustancialmente del pronóstico puntual clásico al adoptar un mecanismo de "parcheo" (patching). Dada una secuencia de series temporales, el modelo segmenta la entrada en parches no superpuestos de una longitud determinada. Cada parche se proyecta linealmente en un espacio de incrustación (embedding) de alta dimensión, acompañado de codificaciones posicionales. La última iteración, TimesFM 2.5, opera con 200 millones de parámetros, lo que representa una reducción altamente optimizada desde su predecesor de 500 millones, y admite longitudes de contexto extendidas de hasta 16,000 puntos de datos.²

Una ventaja arquitectónica crítica de TimesFM es su capacidad para generar parches de salida que son más largos que los parches de entrada. Por ejemplo, el modelo puede procesar parches de entrada de 32 puntos para generar un pronóstico de 128 puntos en un solo paso.⁹ Este diseño mitiga eficazmente el error compuesto que típicamente se asocia con el pronóstico autorregresivo recursivo de un solo paso. Además, TimesFM 2.5 integra covariables exógenas a través de un marco opcional denominado XReg, permitiendo a los modelos de trading incorporar indicadores macroeconómicos, sentimiento de noticias o datos alternativos junto con la acción histórica del precio, transformando la varianza inexplicable en señales predecibles.²

TSPulse de IBM: Aprendizaje de Representación Ultracompacto

Mientras que TimesFM se centra en el pronóstico generativo a través de parámetros a gran escala, TSPulse de IBM introduce una filosofía radicalmente diferente orientada al aprendizaje de representaciones ultracompactas y desenredadas.⁴ Con apenas 1 millón de parámetros, TSPulse está diseñado para inferencia sin necesidad de unidades de procesamiento gráfico (GPU-free), lo que lo hace excepcionalmente valioso para entornos de trading sensibles a la latencia donde los modelos deben ejecutarse en servidores de intercambio colocalizados y limitados por la unidad de procesamiento central (CPU).⁴

TSPulse utiliza una arquitectura basada en TSMixer, alternando bloques de perceptrones multicapa (MLP) con mecanismos de atención de compuerta.³ Su innovación definitoria es su marco de reconstrucción enmascarada de espacio dual durante la fase de preentrenamiento. El modelo aprende explícitamente a desenredar las señales de las series temporales en tres vistas de incrustación complementarias: temporal, espectral (dominio de la frecuencia) y

semántica.¹⁰ Al capturar estructuras de señales complementarias en un espacio de incrustación unificado, TSPulse se vuelve altamente robusto frente a los cambios en el tiempo, la magnitud y el ruido estructural, factores endémicos en los datos financieros.¹²

Para tareas de clasificación, como identificar regímenes de mercado subyacentes o predecir la dirección binaria del movimiento del precio, TSPulse despliega un módulo de ajuste fino especializado llamado *TSLens*. TSLens reemplaza la agrupación promedio global estándar con un mecanismo aprendido que extrae de manera adaptativa características de las incrustaciones de parches de grano fino y los tokens de registro de alto nivel.¹³ IBM proporciona variantes especializadas del modelo, tales como *tspulse-block-dualhead-512-p16-r1*, que está explícitamente optimizada para tareas de clasificación en longitudes de contexto de 512 puntos.⁴

MiniRocket: Transformadas Convolucionales Deterministas

MiniRocket (MINIrmally RandOm Convolutional KErnel Transform) proporciona una alternativa matemática que no pertenece al ámbito del aprendizaje profundo, pero que alcanza una precisión de vanguardia para la clasificación de series temporales a una fracción minúscula del costo computacional de las redes neuronales.⁵ Es la herramienta ideal para la identificación ultrarrápida de patrones en microestructura de mercado y datos de alta frecuencia. A diferencia de las Redes Neuronales Convolucionales (CNN) estándar que aprenden los pesos de los núcleos (kernels) a través de retropropagación (backpropagation), MiniRocket genera un conjunto fijo y determinista de 10,000 núcleos convolucionales. Acelera significativamente el algoritmo original ROCKET al restringir la longitud de los núcleos exactamente a 9 y utilizar un conjunto predefinido de pesos estructurales.¹⁴

Para una secuencia financiera multivariada dada, MiniRocket aplica estos 10,000 núcleos a través de los datos y extrae una sola característica escalar por cada mapa de características utilizando la Agrupación de Proporción de Valores Positivos (PPV, por sus siglas en inglés). El vector de características de 10,000 dimensiones resultante se alimenta luego en un clasificador lineal, casi universalmente un Clasificador de Regresión Ridge (RidgeClassifierCV en implementaciones de scikit-learn). Esta regularización L2 es fundamental, ya que maneja el espacio de características de alta dimensión y fuertemente multicolineal sin sobreajustarse al ruido del mercado.⁶ La elegancia matemática de esta arquitectura permite que MiniRocket sea entrenado en conjuntos de datos financieros masivos en cuestión de minutos, en lugar de los días que requieren los modelos basados en transformadores.⁵

Exploración de Modelos Fundacionales Alternativos

Para establecer una visión comparativa verdaderamente integral del mercado de algoritmos predictivos, es necesario revisar otros modelos matemáticos y arquitecturas de aprendizaje profundo que están demostrando viabilidad en la industria:

- **Chronos (Amazon):** Basado en la arquitectura T5, Chronos tokeniza los datos continuos de las series temporales en contenedores discretos (bins), tratando el pronóstico de mercado estrictamente como un problema de modelado de lenguaje.¹⁶ Chronos sobresale en capacidades de disparo cero y, mediante el uso de la versión Chronos-Bolt,

reduce drásticamente el uso de memoria. Las implementaciones probadas, como las aplicadas a las predicciones de acciones, a menudo ensamblan Chronos con análisis técnico estadístico y mecanismos de cuantificación de incertidumbre para predecir múltiples marcos temporales simultáneamente.¹⁸

- **PatchTST:** Un modelo de transformador que depende en gran medida de la independencia de los canales, tratando las series financieras multivariadas como múltiples series univariadas independientes, y del parcheo intensivo. Es muy valorado en la investigación financiera para el pronóstico de precios a largo plazo.¹⁹
- **MOMENT:** Una familia de modelos de código abierto que enfatiza un preentrenamiento robusto para diversas tareas analíticas. MOMENT ha demostrado un rendimiento excepcional en la detección de anomalías financieras y clasificaciones de regímenes de mercado en simulaciones empíricas, operando sin la necesidad de un entrenamiento específico para cada nueva serie.²¹

Mecanismos de Entrenamiento y Adaptación para Mercados Financieros

Aplicar modelos fundacionales preentrenados directamente en una modalidad de "disparo cero" a los precios de las acciones con frecuencia arroja un rendimiento comparable al lanzamiento aleatorio de una moneda, situándose alrededor del 50% de precisión direccional.²⁴ Los mercados financieros son sistemas adaptativos complejos de segundo orden; por lo tanto, la implementación del usuario descrita en la solicitud requiere protocolos rigurosos de ajuste fino y entrenamiento para extraer cualquier alfa estadísticamente significativo.

Ajuste Fino Eficiente mediante PEFT y LoRA para TimesFM

Las investigaciones institucionales, como las llevadas a cabo por el grupo de investigación PFNet, demuestran de manera inequívoca que si bien el rendimiento directo de TimesFM en precios bursátiles es deficiente, el preentrenamiento continuo en datos financieros mejora drásticamente su eficacia.⁸ La metodología de PFNet involucra el preentrenamiento continuo del modelo utilizando 100 millones de puntos temporales propietarios que abarcan una variedad de instrumentos financieros en granularidades horarias y diarias.⁸

El ajuste fino completo de un modelo de 200 millones de parámetros es computacionalmente prohibitivo para muchos equipos de trading y es propenso al "olvido catastrófico" de los patrones universales aprendidos en la fase de preentrenamiento inicial. En consecuencia, se emplea el Ajuste Fino Eficiente en Parámetros (PEFT), específicamente la Adaptación de Bajo Rango (LoRA).² LoRA congela los pesos del modelo preentrenado e inyecta matrices de descomposición de rango entrenables en las capas del transformador. Matemáticamente, la actualización de los pesos se expresa como una matriz de bajo rango, permitiendo que el modelo se adapte a las particularidades de la estructura de la microestructura del mercado entrenando menos del 1% de los parámetros totales.²⁸

Para el entorno bursátil, las configuraciones de ajuste fino de TimesFM típicamente aplican el Optimizador de Descenso de Gradiente Estocástico (SGD) con un calentamiento lineal (warmup) durante 5 épocas, una tasa de aprendizaje máxima conservadora de $1e-4$, y un

impulso de 0.9 para estabilizar el aprendizaje a través de regímenes volátiles. La longitud del contexto se limita estrictamente (por ejemplo, un máximo de 512 observaciones previas) para predecir un horizonte de salida de 128 pasos.²⁶ Variaciones algorítmicas más avanzadas, como el *Gated DSIC LoRA*, introducen mecanismos de compuerta para enmascarar dinámicamente módulos de LoRA menos importantes durante el entrenamiento, optimizando eficientemente el modelo para la naturaleza altamente estocástica de los retornos de capital.²⁹

Especialización y Entrenamiento de TSLens en TSPulse

La implementación de TSPulse para el trading algorítmico, específicamente en tareas de clasificación como la predicción de movimientos direccionales o la categorización de regímenes de volatilidad, requiere una adaptación meticulosa de sus incrustaciones semánticas. Debido a que TSPulse es ultracompacto, con apenas un millón de parámetros, el ajuste fino global de toda la red neuronal es factible en hardware local. Sin embargo, la mejor práctica institucional estipula congelar la columna vertebral (backbone) del modelo y ajustar exclusivamente el cabezal del clasificador *TSLens* junto con la capa de incrustación del parche de entrada.³⁰

El archivo de instrucciones de entrenamiento debe invocar objetos específicos de la biblioteca de utilidades de modelos, concretamente `TimeSeriesClassificationPreprocessor` y `ClassificationDFDataset`.¹² La canalización se estructura de la siguiente manera: En primer lugar, los datos financieros sin procesar (velas de precios OHLCV y volúmenes) se introducen en el preprocesador, que gestiona el escalado algorítmico y la imputación de valores anómalos o faltantes.³ Seguidamente, el conjunto de datos se estructura en ventanas temporales superpuestas o no superpuestas que deben coincidir imperativamente con la longitud base de contexto del modelo, que para la mayoría de las variantes de TSPulse es de 512 puntos. Para adaptar secuencias de longitud variable, el modelo interpola internamente las entradas a esta dimensión fija.⁴ Finalmente, el bucle de entrenamiento, generalmente implementado en PyTorch utilizando el optimizador AdamW y un programador de tasa de aprendizaje OneCycleLR, fuerza al modelo a mapear las incrustaciones semánticas del historial de 512 periodos a etiquetas direccionales discretas.³¹

Extracción de Características y Optimización Convexa en MiniRocket

El paradigma de entrenamiento de las instrucciones para MiniRocket difiere radicalmente de los enfoques basados en gradientes, funcionando más bien como un proyector de características determinista seguido de una optimización matemática convexa estricta.⁵ La secuencia financiera multivariada se procesa a través de la transformada principal, generando la matriz de características de Proporción de Valores Positivos (PPV) de 10,000 dimensiones.⁶ Posteriormente, las características extraídas se canalizan hacia el estimador `RidgeClassifierCV`. En las matemáticas financieras, las características derivadas de series temporales (como medias móviles múltiples u osciladores sobrecomprados) suelen ser colineales. La penalización L2 introducida en la regresión Ridge encoge los coeficientes correlacionados, logrando una estabilización extrema de las estimaciones. El aspecto de validación cruzada (CV) ajusta automáticamente la fuerza de la regularización, asegurando un

equilibrio óptimo entre el sesgo y la varianza.⁶ Es fundamental observar una advertencia crítica respecto al entrenamiento de MiniRocket en implementaciones comerciales: el uso inadecuado del escalado de datos. Si las instrucciones de precalculo o entrenamiento aplican un StandardScaler de manera global a todo el marco de datos bursátil antes de realizar la división entre datos de entrenamiento y datos de validación, se introduce una fuga de datos severa.³² Al hacer esto, los parámetros de entrenamiento se contaminan irremediablemente con la media y la varianza del futuro, lo que genera una apariencia espuria de alfa predictivo. Todo el escalado debe encapsularse herméticamente dentro de una Pipeline de scikit-learn, asegurando que fit_transform solo analice los pliegues de entrenamiento y aplique las mismas métricas estáticas utilizando únicamente la función transform para los datos fuera de la muestra.³⁴

Análisis Crítico y Optimización de la Implementación del Usuario

El requerimiento del usuario hace referencia a una arquitectura cuantitativa tripartita que incluye un archivo de precalculo de indicadores y matrices matemáticas, un archivo de instrucciones de entrenamiento para los modelos predictivos, y un motor de evaluación histórica (backtester), donde TSPulse se ejecuta en la línea 427 y MiniRocket en la 480. Para identificar posibles puntos ciegos técnicos y áreas de mejora estructural, esta arquitectura debe ser sometida a pruebas de estrés frente a los rigurosos estándares de los fondos cuantitativos y la academia institucional.

Componente del Pipeline	Riesgo de Implementación Ingénua	Práctica Institucional Óptima y Recomendación
Precalculo de Características	Aplicación de Normalización Z-score de manera global. Fugas de alineación temporal al proyectar indicadores.	Generación de estadísticas estrictamente <i>rolling point-in-time</i> . Retrasos (lags) forzados explícitos entre señal y ejecución.
Instrucciones de Entrenamiento	Uso de Validación Cruzada (K-Fold) aleatoria que contamina secuencias temporales.	Optimización rigurosa de avance de ventana (Walk-Forward) o ventanas expansivas preservando la flecha del tiempo.
Motor Backtester (Inferencias)	Bucle iterativo paso a paso de modelos de aprendizaje profundo creando cuellos de botella.	Inferencia tensorial procesada por lotes (batching) preservando la causalidad; uso de

		implementaciones vectorizadas.
Evaluación General	Medición basada únicamente en un Ratio de Sharpe único en una trayectoria histórica.	Validación Cruzada Purgada Combinatoria para deducir la Probabilidad de Sobreajuste (PBO).

La Fase de Precalculo: Mitigación del Sesgo de Anticipación (Look-Ahead Bias)

La práctica de precalcular las características financieras (como la divergencia de convergencia de medias móviles, bandas de volatilidad o firmas matemáticas de la microestructura) es logísticamente altamente eficiente, ya que mitiga los recálculos computacionales redundantes iterando durante el backtesting.³⁶ Sin embargo, la capa de precalculo es históricamente la fuente más prolífica de sesgo de anticipación.

El error de alineación de ejecución (execution-alignment violation) es un modo de fuga de datos nativo del ámbito financiero y extraordinariamente destructivo. Cuando se calculan indicadores técnicos predictivos, la marca de tiempo de la característica procesada debe alinearse ineludiblemente con el instante exacto en que esos datos se vuelven empíricamente ejecutables en un libro de órdenes.³⁸ Por ejemplo, si el precio de cierre de un mercado a las 16:00 horas se utiliza en un cálculo predeterminado, la señal de trading resultante matemáticamente solo puede aplicarse en la apertura del siguiente día de negociación. Si el archivo de precalculo alinea la señal calculada hoy con el índice de tiempo actual y el backtester ejecuta el comercio en ese mismo índice, se ha creado una máquina del tiempo algorítmica. La evidencia empírica en paneles de renta variable demuestra contundentemente que esta fuga selectiva infla los retornos anualizados del backtest a niveles completamente absurdos y no replicables en vivo.³⁸ El código de precalculo del usuario debe ser auditado de principio a fin para garantizar que cada serie calculada aplique un retraso `shift(1)` o su equivalente en índices antes de ser inyectado en las variables independientes del entrenamiento.

Instrucciones de Entrenamiento: La Falacia de la Validación Estándar

El aprendizaje automático estándar aplicado a datos de imágenes o texto no estructurado confía de manera rutinaria en la validación cruzada k-fold aleatoria. En el modelado financiero cuantitativo, esta práctica es matemáticamente desastrosa. Las series temporales de la industria bursátil exhiben fuertes correlaciones seriales y propiedades de agrupamiento de volatilidad persistentes en el tiempo. Al aplicar una partición de pliegues (folds) barajada aleatoriamente, el archivo de instrucciones de entrenamiento filtra información causal del futuro hacia las variables predictoras del pasado.⁴⁰

El archivo de entrenamiento debe imponer obligatoriamente métodos de Validación Cruzada de Avance a Pasos (Walk-Forward Cross-Validation) o de ventana expansiva.⁴⁰ Bajo esta topología algorítmica, la partición de entrenamiento avanza rodando secuencialmente sobre el eje del tiempo, garantizando que el conjunto de prueba (validación) se posicione siempre de manera estrictamente cronológica y posterior a las observaciones de entrenamiento. Esta directriz respeta estrictamente la flecha del tiempo y las dependencias temporales fundamentales de la econometría de mercado, asegurando que las estimaciones de rendimiento no se vean contaminadas por el conocimiento de distribuciones de mercado ex post.⁴² Implementaciones nativas como TimeSeriesSplit deben reemplazar cualquier instanciación de validación k-fold.⁴⁴

Optimización de Topología del Backtester (Líneas 427 y 480)

La descripción funcional provista revela una arquitectura de backtesting donde el flujo de ejecución invoca a TSPulse en la línea 427 y a MiniRocket en la línea 480. Esta integración intercala modelos con requisitos de hardware, características de latencia y estructuras de datos fundamentalmente heterogéneas.

MiniRocket (Línea 480), impulsado por su matriz de convoluciones predeterminadas y resoluciones a través de clasificación Ridge, no sufre las limitaciones severas de memoria asociadas con los modelos transformadores y se resuelve en latencias de inferencia de sub-milisegundos utilizando puramente hilos computacionales de la CPU.⁵ Por el contrario, TSPulse (Línea 427), a pesar de ser comercializado como ultracompacto, sigue requiriendo operaciones tensoriales profundas y bucles de cálculo matricial complejos típicos del aprendizaje profundo.

Si el backtester iterativo del usuario simula los eventos del mercado barra por barra en un bucle temporal, inyectando un solo vector temporal cada vez y esperando el paso de inferencia secuencial de TSPulse, el sistema sufrirá una degradación masiva y exponencial del rendimiento computacional (bottlenecking) en simulaciones prolongadas. Las implementaciones institucionales resuelven esta asimetría refactorizando el diseño del backtester. En lugar de procesar los datos de TSPulse secuencialmente, se agrupan los historiales pasados compatibles causalmente en matrices (batches) y se procesan utilizando clases de DataLoader para optimizar el paso de inferencia de la red, devolviendo los resultados cacheados para su ingesta por el bucle impulsado por eventos sin violar los límites temporales futuros.¹²

Adicionalmente, el rendimiento integral del motor en la línea 480 puede acelerarse al incorporar integraciones orientadas a hardware, como la implementación en GPU de MiniRocket ofrecida por bibliotecas como tsai, facilitando pruebas de estrés a escalas masivas.⁴⁶

Marcos de Prevención de Fugas y Evaluación de Clase Institucional

Para comparar la estructura actual del usuario con "casos probados y exitosos" y deducir mejoras viables, es necesario aplicar los estándares filosóficos y matemáticos pioneros elaborados por el Dr. Marcos López de Prado, el estándar de facto en las finanzas del

aprendizaje automático. En este dominio de bajo ratio señal-ruido, el sobreajuste (overfitting) no es un mero riesgo estadístico, es una certeza determinista y matemática si el proceso de descubrimiento no se aborda mediante procedimientos combinatorios estructurales.⁴⁷

La Matemática del Purguing y el Embargo

Los modelos fundacionales que utilizan ventanas de contexto rodantes amplias (por ejemplo, el diseño de parche de 512 de TSPulse o los bloques de entrada de TimesFM) producen estructuras de conjuntos de datos de entrenamiento en los que las observaciones individuales no son estadísticamente independientes e idénticamente distribuidas (IID). Cuando una ventana temporal de entrenamiento colinda temporalmente de inmediato con una partición de prueba, la memoria matemática subyacente de la serie temporal (la correlación serial) se filtra masivamente a través del punto de división de los datos.⁴¹

La literatura algorítmica más avanzada dicta la intervención ineludible de dos operaciones matemáticas de profilaxis de datos dentro de las instrucciones de entrenamiento:

1. **Purguing (Purgado):** Constituye la eliminación física obligatoria de cualquier registro o matriz de entrenamiento cuyas ventanas de observación históricas se superpongan total o parcialmente con las ventanas temporales que definen la resolución de las etiquetas de prueba. Si una etiqueta binaria u objetivo continuo en el punto temporal T se deriva de la trayectoria de los precios entre T y $T + h$, ningún dato de entrenamiento puede interceptar ese intervalo específico.⁴⁷
2. **Embargo:** Debido a que la inercia del mercado reacciona sistemáticamente a noticias, informes de ganancias y eventos macroeconómicos de manera rezagada durante múltiples periodos, el purgado en el extremo posterior es frecuentemente insuficiente. Se impone un protocolo de "embargo", en el cual una cantidad determinada de datos posteriores al conjunto de validación (típicamente definida matemáticamente como $0.01 \times \text{Nro. de Barras Totales}$) se descartan por completo de manera deliberada para el entrenamiento.⁴⁸ Este foso temporal bloquea efectivamente la anticipación subrepticia en el horizonte del modelo.

Un motor de backtester sofisticado que evalúe modelos predictivos densos y propensos a la memorización como TSPulse debe asimilar orgánicamente estos procesos dentro de sus iteraciones, bajo pena de generar validaciones estadísticas ilusorias e inaplicables.

Validación Cruzada Purgada Combinatoria (CPCV)

La validación tradicional de expansión iterativa hacia adelante (walk-forward clásica) engendra únicamente una simulación patológicamente dependiente del punto de origen específico del inicio del subconjunto de datos. Para derivar una visión integral sobre si la robustez del modelo persistirá fuera de la muestra sin suerte estadística, el marco cuantitativo institucional exige el despliegue de Validación Cruzada Purgada Combinatoria (CPCV).⁴⁸

La CPCV emplea metodologías topológicas complejas para permutar miles de fragmentaciones temporales de conjuntos de entrenamiento y prueba a lo largo de todo el

horizonte del conjunto de datos histórico (mientras se cumplen asiduamente las reglas termodinámicas matemáticas del purgado y el embargo). Esta distribución masiva de evaluaciones cruzadas y caminos alternativos permite al ingeniero de trading calcular una métrica definitoria última: la **Probabilidad de Sobreajuste de Backtest (PBO, por sus siglas en inglés)**.⁴⁸ Si la estructura de software del usuario juzga la eficacia de MiniRocket en la línea 480 exclusivamente sobre los retornos simulados o la métrica del Ratio de Sharpe derivada de un único paso unilineal del conjunto de datos histórico, el riesgo de que la configuración elegida del modelo solo haya memorizado ruido de cola en lugar de descubrir persistencia predictiva se aproxima al 100%. Evaluar las trayectorias bajo el paradigma del PBO otorga una calificación de falsabilidad empírica vital antes de la asignación de capital real.⁴⁸

Casos de Éxito Probados e Implementaciones de Referencia

Contextualizar el diseño actual del usuario requiere mapear implementaciones basales exitosas y topologías de mercado en la industria cuantitativa con los modelos descritos.

Implementación de Topología Neutral al Mercado mediante TimesFM

Una investigación y simulación institucional crítica llevada a cabo por los ingenieros financieros de PFNet documenta explícitamente el uso empírico exitoso del modelo TimesFM ajustado en mercados de capitales.⁵¹ La investigación determinó empíricamente que la invocación ingenua (cero disparos o sin intervención matemática financiera previa) de la arquitectura subyacente generaba pérdidas sistemáticas ininterrumpidas durante la ejecución de los marcos temporales de mercado en activos como el S&P 500 y el TOPIX500, llegando a rendimientos anualizados negativos de -0.24%.⁵¹ Sin embargo, al transformar la predicción bruta del modelo tras someterlo a la estricta canalización de entrenamiento y ajuste fino continuo (PEFT) delineado anteriormente, sus estimaciones demostraron una precisión estructural.

El caso de éxito no se originó en la ejecución de compras directas de instrumentos individuales, sino mediante la formulación arquitectónica sistemática de una cartera de cobertura cruzada, conocida en la industria como un enfoque **Neutral al Mercado (Market Neutral)**. En lugar de apostar en valores de precios absolutos de futuros (que tienden a degradarse bajo regímenes altamente volátiles), se estructuró un algoritmo donde el modelo TimesFM predice un panel transversal, o vector en sección cruzada de rentabilidades futuras de cientos de activos.⁵¹ Se instancian estrategias donde se toman posiciones largas en las acciones que generan las probabilidades de predicción superior y posiciones cortas proporcionales en los pronósticos marginales más bajos.⁴¹ Esta topología particular implementada con la fundación preentrenada produjo una simulación de operaciones consistentemente superior a los modelos AR e impulsores de referencia, generando un impresionante Ratio de Sharpe anualizado fuera de muestra de 1.68 en acciones del S&P500.⁵¹ El pilar vital a emular en la implementación del usuario radica en no forzar la generación de pronósticos determinísticos en puntos absolutos, sino permitir que el modelo actúe como un clasificador ordenado probabilísticamente a través del universo transversal en el que opera.

Intersección Sinérgica de Ensamblados: MiniRocket e Inteligencia Basada en Árboles

En topologías del mercado de la vida real, ningún marco de modelado neuronal captura por sí solo toda la dinámica estadística oscilatoria presente en un marco financiero complejo sin rendimientos marginales decrecientes de generalización. Como tal, el estado del arte a menudo invoca enfoques metodológicos híbridos. Un excelente ejemplo validado en estudios recientes demuestra el ensamblado o amalgama matemática de las firmas de MiniRocket con el Algoritmo Computacional de Incremento de Gradiente Extremo de los Árboles de Decisión (XGBoost o CatBoost).⁵²

En arquitecturas donde la clasificación unidimensional como la derivada de una Regresión lineal o RidgeClassifierCV resulta vulnerable debido a rupturas estructurales impredecibles o alta volatilidad heterogénea sistémica impulsada por choques externos (como un colapso macroeconómico exógeno), el protocolo transfiere la matriz matemática precalculada de vectores de 10,000 proporciones de PPV como características directas adicionales en la entrada vectorial multidimensional hacia un bosque de XGBoost, enlazado adicionalmente con variables exógenas como índices fundamentales.⁵² La razón intrínseca de esta topología se debe a que la red neuronal subyacente de los modelos en la clase Boost gestiona imperativamente e implícitamente subespacios ortogonales irregulares y la multicolinealidad, a menudo logrando clasificaciones de dirección predictiva en entornos seriamente fuera de equilibrio, mitigando deficiencias de linealidad que RidgeCV no podría acomodar óptimamente.⁵²

Asimilación Condicional de Variables Multi-Dominio (Covariables)

Uno de los mayores fallos inherentes descubiertos empíricamente de las aproximaciones de series temporales iniciales fue el "aislamiento predictivo", procesar e interrogar las arquitecturas de pronósticos únicamente operando sobre variables endógenas autorregresivas (univariadas). Como declaran expresamente los investigadores cuantitativos y las métricas formales implementadas, requerirle a TimesFM inferir un vector en una serie restringida a sí misma equivaldría virtualmente a operar ciegamente mientras se extrapolaban extrapolaciones del vacío. A menudo identifica estacionalidad, pero la correlación subyacente no causal.⁹ Implementaciones de vanguardia con modelos base como Chronos o integraciones avanzadas XReg recientes en la biblioteca de TimesFM 2.5 explícitamente fuerzan el enrutamiento y asimilación condicional de tensores exógenos integrales multivariados.² Una recomendación absoluta para alterar el archivo de precalculo y backtester actual sería diseñar matrices tensoriales integrando vectores como flujos macro de la estructura a plazo (term structure), estimaciones interbancarias, métricas de actividad implícitas de derivados OTC y cuantificación empírica de métricas del ecosistema de redes sociales y sentimientos. El efecto neto reduce profundamente los intervalos de incertidumbre estocástica, anclando el conocimiento puramente autorregresivo del modelo del mercado a las directrices termodinámicas subyacentes del mundo real, eliminando desviaciones y volatilidades estructuralmente inexploradas.⁹

Conclusiones Críticas y Directrices de Remediación Integrales

La adopción de modelos predictivos avanzados fundacionales de aprendizaje profundo como TimesFM, junto con componentes deterministas compactos de vanguardia como TSPulse y MiniRocket, proporciona un arsenal matemático cuantitativo invaluable para estructurar algoritmos bursátiles, pero invariablemente magnifica asimetrías de riesgo operativo si no está atado intrínsecamente a metodologías epistemológicas correctas de infraestructura de canalización.

Sobre la base del extenso análisis comparativo estructurado a lo largo de esta investigación, el usuario de la arquitectura de comercio estipulada deberá proceder a aplicar el siguiente esquema riguroso y analíticamente respaldado a su base de código, precalculos, instrucciones paramétricas y lógica de inferencia iterativa:

1. **Auditoría y Descontaminación del Precalculo:** Someter los archivos de ingeniería de precalculo a pruebas destructivas rigurosas orientadas a aislar y amputar cualquier infiltración causal invertida y violaciones de alineación de ejecución. Si las firmas o las señales se derivan de cierres absolutos en el horizonte t , su aplicación transaccional en la canalización del backtester debe someterse a cierres estrictos de retraso posicional $t+1$ y proyecciones dinámicas puramente del pasado para normalización, prohibiendo asiduamente bibliotecas preconstruidas de estandarización completa como StandardScaler de procesamiento pre-partición de datos cruzados.³²
2. **Imposición Rigurosa de Restricciones Epidemiológicas de Entrenamiento:** El bucle paramétrico del algoritmo de aprendizaje debe transicional imperativamente desde paradigmas desastrosos de validación pseudoaleatoria no direccional de datos cruzados (K-Fold) para implementar y honrar estricta metodología secuencial basada en cronología y avance (Walk-Forward). Más críticamente aún, esta actualización procedimental estará intrínsecamente entrelazada operativamente al mandato inquebrantable que estipula aislar y purgar variables estructurales superpuestas transfronterizas entre marcos, además de embargar los remanentes posteriores a la prueba del mercado general.⁴⁰
3. **Refactorización y Armonización Heterogénea del Motor Central de Inferencia:** Dado que las líneas del código objeto evalúan iteraciones funcionales cruzadas asimétricas —los requisitos computacionales de hardware profundo multivariados de TSPulse (Línea 427) yuxtapuestos con la evaluación convexa rápida del núcleo CPU escalar de MiniRocket (Línea 480)— el entorno unificado deberá abstenerse de llamadas de red recursivas asíncronas lentas para estructurar canalizaciones por lotes paralelas masivamente simultáneas y sin latencia transaccional.³
4. **Reingeniería Topológica Estructural en Modelado Direccional (Aplicaciones Prácticas de Rendimiento de Vanguardia):** Abandonar las proyecciones predictivas solitarias direccionales absolutas impulsadas por TimesFM por carteras matemáticas analíticas de clasificación probabilística en sección transversal Neutral al Mercado que minimicen los riesgos por volatilidades sistémicas sistémicas del factor macroestructural

de beta del entorno global.⁵¹ Además, garantizar inequívocamente que los modelos integrados a la infraestructura de entrenamiento sufran protocolos paramétricos obligatorios de ajuste continuo eficientes a través del mecanismo subyacente algorítmico de adaptaciones de bajo rango (PEFT/LoRA) y ajuste dinámico en TSLens para sincronizar armónicamente la ontología subyacente aprendida de base cero a la idiosincrasia bursátil de ruido aleatorio real y continuo inherente al modelo final.

Obras citadas

1. TimesFM models in BigQuery and AlloyDB | Google Cloud Blog, fecha de acceso: junio 18, 2026, <https://cloud.google.com/blog/products/data-analytics/timesfm-models-in-bigquery-and-alloydb>
2. GitHub - google-research/timesfm: TimesFM (Time Series Foundation Model) is a pretrained time-series foundation model developed by Google Research for time-series forecasting., fecha de acceso: junio 18, 2026, <https://github.com/google-research/timesfm>
3. Time Series Analysis with Granite Time - IBM, fecha de acceso: junio 18, 2026, <https://www.ibm.com/think/tutorials/time-series-analysis-granite-time-tspulse>
4. ibm-granite/granite-timeseries-tspulse-r1 - Hugging Face, fecha de acceso: junio 18, 2026, <https://huggingface.co/ibm-granite/granite-timeseries-tspulse-r1>
5. MiniRocket: a very fast (almost) deterministic transform for time series classification, fecha de acceso: junio 18, 2026, <https://research.monash.edu/en/publications/minirocket-a-very-fast-almost-deterministic-transform-for-time-series/>
6. MiniRocket — sktime documentation, fecha de acceso: junio 18, 2026, <https://www.sktime.net/en/stable/examples/transformation/minirocket.html>
7. A decoder-only foundation model for time-series forecasting - Google Research, fecha de acceso: junio 18, 2026, <https://research.google/blog/a-decoder-only-foundation-model-for-time-series-forecasting/>
8. Financial Fine-tuning a Large Time Series Model - IDEAS/RePEc, fecha de acceso: junio 18, 2026, <https://ideas.repec.org/p/arx/papers/2412.09880.html>
9. TimesFM: Using Google's Foundation Model for Time Series Forecasting | by Siduo Jiang, fecha de acceso: junio 18, 2026, <https://medium.com/@siduojiang/timesfm-using-googles-foundation-model-for-time-series-forecasting-3da90d07bdd7>
10. TSPulse: Tiny Pre-Trained Models with Disentangled Representations for Rapid Time-Series Analysis - ICLR 2026, fecha de acceso: junio 18, 2026, <https://iclr.cc/virtual/2026/poster/10010081>
11. [2505.13033] TSPulse: Tiny Pre-Trained Models with Disentangled Representations for Rapid Time-Series Analysis - arXiv, fecha de acceso: junio 18, 2026, <https://arxiv.org/abs/2505.13033>
12. granite-timeseries-cookbook/recipes/Search/Getting_Started_with_TSPulse_Search.ipynb at main - GitHub, fecha de acceso: junio 18, 2026,

- https://github.com/ibm-granite-community/granite-timeseries-cookbook/blob/main/recipes/Search/Getting_Started_with_TSPulse_Search.ipynb
13. TSPulse: Dual Space Tiny Pre-Trained Models for Rapid Time-Series Analysis - arXiv, fecha de acceso: junio 18, 2026, <https://arxiv.org/html/2505.13033v1>
 14. Time series classification with random convolution kernels: pooling operators and input representations matter - arXiv, fecha de acceso: junio 18, 2026, <https://arxiv.org/html/2409.01115v2>
 15. A Comparison of Deep Learning and Established Methods for Calf Behaviour Monitoring - arXiv, fecha de acceso: junio 18, 2026, <https://arxiv.org/pdf/2408.13041?>
 16. Introducing Chronos-2: From univariate to universal forecasting - Amazon Science, fecha de acceso: junio 18, 2026, <https://www.amazon.science/blog/introducing-chronos-2-from-univariate-to-universal-forecasting>
 17. amazon-science/chronos-forecasting: Chronos: Pretrained Models for Time Series Forecasting - GitHub, fecha de acceso: junio 18, 2026, <https://github.com/amazon-science/chronos-forecasting>
 18. Advanced Stock Prediction Analysis with Amazon Chronos - a Hugging Face Space by Tonic, fecha de acceso: junio 18, 2026, <https://huggingface.co/spaces/Tonic/stock-predictions>
 19. An official implementation of PatchTST: "A Time Series is Worth 64 Words: Long-term Forecasting with Transformers." - GitHub, fecha de acceso: junio 18, 2026, <https://github.com/PatchTST/PatchTST>
 20. lacomaofficial/Transformer-Time-Series-Model: Multivariate and Univariate Analysis using Deep Learning - GitHub, fecha de acceso: junio 18, 2026, <https://github.com/lacomaofficial/Transformer-Time-Series-Model>
 21. Time-MoE: Billion-Scale Time Series Foundation Models with Mixture of Experts, fecha de acceso: junio 18, 2026, <https://openreview.net/forum?id=e1wDDFmlVu>
 22. Recent Advances in Time Series Foundation Models: Have We Reached the 'BERT Moment'? - NeurIPS 2026, fecha de acceso: junio 18, 2026, <https://neurips.cc/virtual/2025/workshop/109585>
 23. ICML Poster In-Context Fine-Tuning for Time-Series Foundation Models, fecha de acceso: junio 18, 2026, <https://icml.cc/virtual/2025/poster/43707>
 24. Has anyone had success using transformer-based models for stock/crypto price prediction?, fecha de acceso: junio 18, 2026, https://www.reddit.com/r/learnmachinelearning/comments/1jsly7p/has_anyone_had_success_using_transformerbased/
 25. Financial Fine-tuning a Large Time Series Model - arXiv, fecha de acceso: junio 18, 2026, <https://arxiv.org/html/2412.09880v1>
 26. pfnet-research/timesfm_fin - GitHub, fecha de acceso: junio 18, 2026, https://github.com/pfnet-research/timesfm_fin
 27. timesfm/timesfm-forecasting/examples/finetuning · ti/timesfm, fecha de acceso: junio 18, 2026, https://gitcode.com/GitHub_Trending/ti/timesfm/tree/master/timesfm-forecasting/examples/finetuning/

28. How to Implement LoRA with Hugging Face PEFT: Step-by-Step Tutorial - YouTube, fecha de acceso: junio 18, 2026,
https://www.youtube.com/watch?v=F29Y_y7g6lY
29. TRACE: Time SeRIes PArAmeter EffiCient FinE-tuning - arXiv, fecha de acceso: junio 18, 2026, <https://arxiv.org/html/2503.16991v2>
30. granite-tsfm/notebooks/hfdemo/tspulse_classification.ipynb at main - GitHub, fecha de acceso: junio 18, 2026,
https://github.com/ibm-granite/granite-tsfm/blob/main/notebooks/hfdemo/tspulse_classification.ipynb
31. granite-timeseries-cookbook/recipes/Classification/Getting_Started_with_TSPulse_Classification.ipynb at main - GitHub, fecha de acceso: junio 18, 2026,
https://github.com/ibm-granite-community/granite-timeseries-cookbook/blob/main/recipes/Classification/Getting_Started_with_TSPulse_Classification.ipynb
32. 3 Subtle Ways Data Leakage Can Ruin Your Models (and How to Prevent It), fecha de acceso: junio 18, 2026,
<https://machinelearningmastery.com/3-subtle-ways-data-leakage-can-ruin-your-models-and-how-to-prevent-it/>
33. Is it correct to use a single StandardScaler before splitting data? - Stack Overflow, fecha de acceso: junio 18, 2026,
<https://stackoverflow.com/questions/63037248/is-it-correct-to-use-a-single-standardscaler-before-splitting-data>
34. 12. Common pitfalls and recommended practices - Scikit-learn, fecha de acceso: junio 18, 2026, https://scikit-learn.org/stable/common_pitfalls.html
35. Which Leakage Types Matter? A Quantitative Landscape Across 2,047 Benchmark Datasets, fecha de acceso: junio 18, 2026,
<https://arxiv.org/html/2604.04199v1>
36. Systems building - futures rolling - This Blog is Systematic, fecha de acceso: junio 18, 2026,
<https://qoppac.blogspot.com/2015/05/systems-building-futures-rolling.html>
37. Introduction To AmiBroker Second Edition | PDF | File Format - Scribd, fecha de acceso: junio 18, 2026,
<https://www.scribd.com/document/123447775/Introduction-To-AmiBroker-Second-Edition>
38. When Alpha Disappears: A One-Switch Benchmark for Decision-Time Leakage in Financial Backtests - arXiv, fecha de acceso: junio 18, 2026,
<https://arxiv.org/html/2605.23959v1>
39. Quant-Safe Explainable Artificial Intelligence for Dynamic Portfolio Management A Reproducible, Leakage-Resistant ML + SHAP Framework with Execution-Grade Accounting Logs - Preprints.org, fecha de acceso: junio 18, 2026,
<https://www.preprints.org/manuscript/202601.1636>
40. Machine Learning in Econometrics - by Simone Menaldo - Medium, fecha de acceso: junio 18, 2026,
<https://medium.com/@simomenaldo/machine-learning-in-econometrics-71af7b4f1958>
41. Financial Machine Learning, fecha de acceso: junio 18, 2026,

- https://bfi.uchicago.edu/wp-content/uploads/2023/07/BFI_WP_2023-100.pdf
42. TempusBench: An Evaluation Framework for Time-Series Forecasting - arXiv, fecha de acceso: junio 18, 2026, <https://arxiv.org/html/2604.11529v2>
 43. TempusBench: An Evaluation Framework for Time-Series Forecasting - arXiv, fecha de acceso: junio 18, 2026, <https://arxiv.org/html/2604.11529v1>
 44. TimeSeriesSplit — scikit-learn 1.9.0 documentation, fecha de acceso: junio 18, 2026, https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.TimeSeriesSplit.html
 45. tsai/tutorial_nbs/10_Time_Series_Classification_and_Regression_with_MiniRocket.ipynb at main - GitHub, fecha de acceso: junio 18, 2026, https://github.com/timeseriesAI/tsai/blob/main/tutorial_nbs/10_Time_Series_Classification_and_Regression_with_MiniRocket.ipynb
 46. MINIROCKET: A Very Fast (Almost) Deterministic Transform for Time Series Classification - GitHub, fecha de acceso: junio 18, 2026, <https://github.com/angus924/minirocket>
 47. Advances in Financial Machine Learning - Reasonable Deviations, fecha de acceso: junio 18, 2026, https://reasonabledeviations.com/notes/adv_fin_ml/
 48. Unified Validation Pipeline Against Backtest Overfitting - MQL5 Articles, fecha de acceso: junio 18, 2026, <https://www.mql5.com/en/articles/21603>
 49. Advances in Financial Machine Learning: Lecture 6/10 | Request PDF - ResearchGate, fecha de acceso: junio 18, 2026, https://www.researchgate.net/publication/328211649_Advances_in_Financial_Machine_Learning_Lecture_610
 50. francescodisalvo05/66DaysOfData: #66DaysOfData challenge in Financial Machine Learning and NLP - GitHub, fecha de acceso: junio 18, 2026, <https://github.com/francescodisalvo05/66DaysOfData>
 51. Predicting market prices with a financial time series foundation model - Preferred Networks Tech Blog, fecha de acceso: junio 18, 2026, <https://tech.preferred.jp/en/blog/timesfm/>
 52. Comparative analysis of ROCKET-driven and classic EEG features in predicting attachment styles - PMC, fecha de acceso: junio 18, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC10882770/>
 53. Re(Visiting) Time Series Foundation Models in Finance - arXiv, fecha de acceso: junio 18, 2026, <https://arxiv.org/html/2511.18578v1>
 54. rachnaumesh/StockForecasting: Multimodal Deep Learning for Stock Prediction : A comprehensive approach using transformer architectures and sentiment analysis - GitHub, fecha de acceso: junio 18, 2026, <https://github.com/rachnaumesh/StockForecasting>